

## Median of Medians on Selection - Sort [für Auswahlproblem]

Algorithmus Auswahl( $A, i$ )

- 1) Wähle Pivot-Element  $x \in A$
- 2)  $A_{<x} \leftarrow \{a \in A \mid a < x\}$ ,  $A_{>x} \leftarrow \{a \in A \mid a > x\}$
- 3) if  $|A_{<x}| = i-1$  then return  $x$
- 4) else if  $|A_{<x}| \geq i$  then return Auswahl( $A_{<x}, i$ )
- 5) else return Auswahl( $A_{>x}, i-1-|A_{<x}|$ )

Optimierung passiert im Schritt 1)

- 1) - randomisierter Linearzeit - Algorithmus
- 2) - deterministischer Linearzeit - Algorithmus

Hier wird 2) im Schwerpunkt diskutiert.

Ersetze Schritt 1) durch folgende Routine

- i) partitioniere  $A$  in  $\lfloor |A|/5 \rfloor$  Teilmengen mit 5 Elementen und eine Teilmenge mit den restlichen  $(n \bmod 5)$  Elementen - Laufzeit  $O(|A|)$
- ii) Bestimme für jede dieser Teilmengen deren Median und bilde  $A_M$  dieser Mediane - Laufzeit  $O(|A|)$
- iii) Berechne mittels rekursivem Aufruf von 'Auswahl' den Median  $x$  von  $A_M$  und verwende  $x$  als Pivot-Element.

Jetzt machen wir  $\star$  Laufzeit-Analyse

课件里直接给出

$$\bullet |A_M| = \lceil \frac{n}{5} \rceil$$

$$\bullet |A_{>x}| \geq 3 \cdot \left( \lceil \frac{1}{2} \lceil \frac{n}{5} \rceil \rceil - 2 \right) \geq \frac{3n}{10} - 6 \quad \Rightarrow |A_{<x}| \leq \left\lfloor \frac{7n}{10} + 6 \right\rfloor$$

$$\bullet \text{ analog: } |A_{<x}| \geq \frac{3n}{10} - 6 \quad \Rightarrow |A_{>x}| \leq \left\lfloor \frac{7n}{10} + 6 \right\rfloor$$

Folglich gilt für die monotone Laufzeitfunktion des rekursiven Algorithmus

$$f(n) \leq f\left(\lceil \frac{n}{5} \rceil\right) + f\left(\left\lfloor \frac{7n}{10} + 6 \right\rfloor\right) + cn, \text{ für ein } c > 0 \text{ und alle } n \in \mathbb{N}_{>0}$$

详细解释见网页

1) 为什么  $|A_M| = \lceil \frac{n}{5} \rceil$

因为按照前面对  $\Pi$  的描述, 我们把集合  $A$  分成了大小为 5 的小组。  
每组取一个中位数。

设  $|A| = n$ , 可以分为  $\lfloor \frac{n}{5} \rfloor$  个小组, 共有 5 个元素, 考虑到  $n$  不一定能整除 5, 于是可能存在最后一个小组, 它有  $n \bmod 5$  个元素。②

所以我们一共有  $\lfloor \frac{n}{5} \rfloor + 1$ , 即  $\lceil \frac{n}{5} \rceil$  个小组。

$A_M$  是一个集合, 它有  $\lfloor \frac{n}{5} \rfloor + 1 = \lceil \frac{n}{5} \rceil$  个元素。

2)  $x$  是什么, 它有什么影响?

$x$  来自于 ii). 它是  $A_M$  集合中的中位数。

因为  $x$  是中位数, 所以在  $A_M$  中, 至少有一半的数大于  $x$ , 至少有一半的数小于  $x$ 。①

$x$  是在  $A_M$  中用递归的方式找到的, 它会被用作全局 Pivot。 (iii)

3)  $|A_{>x}| \geq 3(\lceil \frac{1}{2} \lceil \frac{n}{5} \rceil - 1)$  是怎么推导出来的

在  $A_M$  中至少有  $\lceil |A_M|/2 \rceil$  个数  $\geq x$

e.g.  $a_1 \boxed{a_2 \ a_3 \ a_4}$   
           $\uparrow$   
       $a_1 \ a_2 \ \boxed{a_3 \ a_4}$   
                   $\uparrow$   
       $a_1 \ a_2 \ \boxed{a_3 \ a_4 \ a_5}$   
                           $\uparrow$

再由  $A_M$  到观察具体的 5-元素一组

$a \in A_M$ , mit  $a \geq x$

$a_1 \ a_2 \ a_3 \ a_4 \ a_5 \Rightarrow a_5 > a_4 > a_3$ , 所以每组至少有 3 个元素大于/等于  $x$

~~考虑到最后 5 个元素可能不是 5 个元素~~

考虑到最后一个小组可能不足 5 个元素, 于是  $\lceil \frac{|A_M|}{2} \rceil - 1$

考虑到中位数可能恰等于  $x$  的那一组, 那么只有 2 个元素比  $x$  大, 于是  $\lceil \frac{|A_M|}{2} \rceil - 1$   
比如  $\{1, 2, x, x+1, x+2\}$  这里只有  $x+1, x+2$  比  $x$  大

综上  $3 \cdot (\lceil \frac{|A_M|}{2} \rceil - 1 - 1) \leq |A_{>x}|$ ,  $|A_M| = \lceil \frac{n}{5} \rceil$

于是得到安全的下界

排除掉极端情况后, 剩下的小组就可以 100% 保证“每个贡献至少 3 个元素  $\geq x$ ” 2



在上文, 我们已得  $|A_{\geq x}| \geq 3 \cdot \left( \left\lceil \frac{|A_M|}{2} \right\rceil - 2 \right) = 3 \cdot \left( \left\lceil \frac{n}{5} \right\rceil \cdot \frac{1}{2} - 2 \right) \geq \frac{3n}{10} - 6$

~~所以~~

同理, 在  $A_M$  里至少有一半的数  $\leq x$

每个这样的 5 元素小组里至少有 3 个元素  $\leq$  该组中位数  $\leq x$

所以  $|A_{< x}| \geq \frac{3n}{10} - 6$

这说明 pivot 至少去掉了 30% 的元素,

$\Rightarrow$  剩下的子问题大小, 最多是

$$n - \left( \frac{3n}{10} - 6 \right) = \frac{7n}{10} + 6$$

$$\Rightarrow |A_{> x}| \geq \frac{3n}{10} - 6 \quad \Rightarrow |A_{< x}| \leq \left\lfloor \frac{7n}{10} + 6 \right\rfloor$$

$$|A_{< x}| \geq \frac{3n}{10} - 6 \quad \Rightarrow \text{~~A_{> x}}~~ |A_{> x}| \leq \left\lfloor \frac{7n}{10} + 6 \right\rfloor$$

由此, 递归运行时间满足

$$f(n) \leq f\left(\left\lceil \frac{n}{5} \right\rceil\right) + f\left(\left\lfloor \frac{7n}{10} + 6 \right\rfloor\right) + c \cdot n, \text{ für ein } c > 0 \text{ und } n \in \mathbb{N}_{>0}$$

其中  $f\left(\left\lceil \frac{n}{5} \right\rceil\right)$ : 递归在  $A_M$  上中位数

$f\left(\left\lfloor \frac{7n}{10} + 6 \right\rfloor\right)$ : 递归最多在 70% 的剩余元素上继续查找

$c \cdot n$  : partition cost

最后来个 Satz: Wählt man im Algorithmus 'Auswahl' das Pivot-Element mit der oben beschriebenen rekursiven Routine, dann ist die Laufzeitfunktion in  $O(n)$ .

Beweis ist Teil der letzten Seite.

K8. Median-of-Medians 思想 für Lösung des Auswahlproblems in erwarteter linear Zeit

Beobachtung: Wählt man Pivot-Element  $x$  in Linearzeit so, dass

$$\max \{ |A_{<x}|, |A_{>x}| \} \leq Ld \cdot |A|$$

für eine konstante  $d < 1$ , so hat Auswahl  $(A, i)$  Laufzeit  $O(n)$

Beweis: Für Laufzeitfunktion  $f: N \rightarrow N$  gilt dann

$$f(n) \leq f(Ld \cdot n) + \tilde{c} \cdot n$$

$d \cdot n$ : Subproblemgröße

$f(Ld \cdot n)$ : Rekursiver Aufruf, d.h. die Zeit für das Problem der Größe  $Ld \cdot n$

$\tilde{c} \cdot n$ : Partition cost, Aufwandskosten.

Warum sind Aufwandskosten  $\tilde{c} \cdot n$ ?

Wenn wir ein Pivot  $x$  wählen, müssen wir die Menge in drei Teile

$$A_{<x}, A_{=x}, A_{>x}$$

Wir müssen das gesamte Array durchsuchen, für jedes Element eine Vergleichsoperation durchführen, um zu entscheiden, ob es links oder rechts von  $x$  liegt. Jedes Element wird höchstens einmal mit  $x$  verglichen.

Also sind die Kosten  $O(n)$ .

Für  $f(n)$  die Laufzeit, gibt es zwei Beweismethoden:

Methoden:  $f(n) \leq f(dn) + cn$

$$\leq (f(d^2n) + c \cdot (dn)) + cn \quad * \text{ mit } n = dn$$

$$\leq (f(d^3n) + c \cdot (d^2n)) + c \cdot (dn) + cn$$

...

$$\leq f(d^k n) + cn \cdot (d^0 + d^1 + d^2 + \dots + d^{k-1})$$

$$\text{weil } d < 1 \Rightarrow d^0 + d^1 + \dots + d^{k-1} = \sum_{j=0}^{k-1} d^j = \frac{1-d^k}{1-d}$$

$$\Rightarrow f(n) \leq cn \cdot \frac{1}{1-d} + f(d^k n)$$

$$\text{weil } d^k \rightarrow 0, k \rightarrow \infty$$

$$\Rightarrow f(n) \leq cn \cdot \frac{1}{1-d} + t, t \in \mathbb{R}$$

$$\Rightarrow f(n) \in O(n)$$

方法 2:

use verallgemeinerter Aufteilungs- Beschleunigungs- Satz

Es sei:  $f: \mathbb{R}_{\geq 0} \rightarrow \mathbb{R}_{\geq 0}$  monoton wachsend,  $a \in \mathbb{R}_{>1}$ ,  $b, c \in \mathbb{R}_{\geq 0}$ ,  
so dass  $f(1) \leq \frac{c}{a}$ , und die folgende Ungleichung gilt:

$$f(a \cdot n) \leq b \cdot f(n) + c \cdot n, \text{ für alle } n \geq 1$$

Dann gilt:

$$f(n) = \begin{cases} O(n) & , a > b \\ O(n \log n) & , a = b \\ O(n^{\log_a b}) & , a < b \end{cases}$$

对于这个问題:

$$f: \mathbb{N} \rightarrow \mathbb{N}, \text{ dann gilt } f(n) \leq f(\lfloor d \cdot n \rfloor) + \tilde{c} n$$

我们把公式放一起比较

$$f(n) \leq f(\lfloor d \cdot n \rfloor) + \tilde{c} n$$

$$f(a \cdot n) \leq b \cdot f(n) + c n$$

$$\Rightarrow b=1 \quad \lfloor d \cdot n \rfloor \cdot a = a n$$

$$\Rightarrow a = \left\lceil \frac{1}{d} \right\rceil$$

$$\text{denn } d < 1 \Rightarrow a > 1, \Rightarrow a > b$$

$$\Rightarrow f(n) \in O(n)$$

**Satz:** Wählt man in Algorithmus Auswahl  $(A, i)$  das Pivot-Element  $x \in A$  zufällig und gleichverteilt, so ist erwartete Laufzeit  $O(n)$   
证明见课件